

tanh com o ganho calibrado pela própria ativação

Sem BatchNorm e sem conexões residuais, cada camada **multiplica** a variância do sinal por um fator. Se esse fator não for 1, em 48 camadas o sinal some ou explode. Nós calculamos o fator exato da tanh e cancelamos ele na inicialização.

$$s^2 = 1 / (fan_in \cdot E[f(z)^2])$$

$E[\tanh(z)^2] = 0,3943 \rightarrow fan_in \cdot s^2 = 2,536$
 estimado por Monte Carlo, 10^6 amostras · viés zero · última camada $\times 0,5$

